Ciencia De Datos

Riesgo Crediticio

Ricardo Rodríguez Ovilla

Septiembre 2023

Contents

Introducción **1**

Definiciones **2**
2.1 Diccionario de las variables 2
2.2 Definición Variable Objetivo 4

Calidad De Datos **6**
3.3 Duplicidad 6
3.4 Completitud 6
3.5 Consistencia 7
3.6 Precisión 7
3.7 Normalización 7

Análisis Exploratorio **8**

Outliers **13**
4.8 Local Outlier Factor 13
4.9 Isolation Forest 13
4.10 Implementación 14

Ingeniería de Variables **18**
5.11 One-Hot encoding (Dummies) 18
5.12 Variables Continuas 18

Modelos **20**
6.13 Re-balanceo de la Clase Minoritaria 20
6.14 Clasificadores 21
6.14.1 Recurrent neural network 21
6.14.2 Random Forest 21
6.14.3 Linear discriminant analysis (LDA) 22
6.14.4 Quadratic Discriminant Analysis (QDA) 23

6.14.5 Gradient Boosting 24
6.15 Selección Final 25

Modelación No Supervisada **26**
7.16 Introducción 26
7.16.1 Euclidiana 26
7.16.2 Manhattan 26
7.16.3 Jackknife 27
7.16.4 Simple Matchinfg Coefficient 27
7.16.5 Indice Jaccard 27
7.16.6 Distancia Coseno 28
7.16.7 Estandarización de variables 28
7.17 Reducción de Dimensión 29
7.17.1 Componentes Principales 29
7.17.2 Multidimensional Scaling 31
7.18 Clusters 32
7.18.1 K-Medias 32
7.18.2 Mixturas Gaussianas 34
7.18.3 DBSCAN 37
7.18.4 Perfilamiento y Estabilidad 39
7.18.5 Caso Practico: Proyecto 41

Deep Learning **45**
8.19 Introducción 45
8.20 Funciones de activación 45
8.21 Explotasion y desvanecimiento del gradiente 47
8.22 Funciones de costo en redes neuronales 48
8.23 Backpropagation 49
8.24 Descenso de Gradiente 51
8.25 Tipos de Gradiente Descendente 52
8.26 Regularización 54
8.26.1 Early Stopping 54
8.26.2 Dropout 55
8.27 Aplicación 56

Introducción

El aumento de la competencia y las crecientes presiones para la generación de ingresos han llevado a las instituciones otorgantes de crédito y otras instituciones financieras a buscar formas más efectivas de atraer nuevos clientes solventes y, al mismo tiempo, controlar las pérdidas.

Sin embargo una ves que el cliente ya posee el instrumento de crédito el problema que inicialmente fue evaluado con variables de originación (variables que se pueden obtener desde un primer acercamiento del cliente a la institución financiera como edad , salario , etc..) ahora se convierte en un problema con variables dinámicas ya que podemos darle seguimiento al cliente con la finalidad de administrar el portafolio de todos los clientes activos con un instrumento de crédito.

Esto con la finalidad de generar estrategias sobre segmentos de la poblacion con comportamiento especifico ya que los recursos son limitados y deben ser optimizados de alguna forma.

Para clientes con alta probabilidad de caer en mora se les puede activar herramientas de cobranza como llamadas , recordatorios de pagos o en el peor de los casos reestructuras a sus créditos para evitar que el cliente no pueda hacer los pagos del mismo.

Para clientes que han mostrado un comportamiento excelente con el uso de sus créditos se les podría ofrecer otros tipos de productos (ofertas cruzadas), mejorar condiciones de su crédito existente para evitar que otras instituciones les ofrezcan mejores condiciones y perder al cliente.

Un ejemplo de esto seria en productos hipotecarios ya que entre bancos buscan ofrecer a los clientes comprar las deudas que tienen con otras instituciones si este ha mostrado buen comportamiento y así obtener clientes con baja probabilidad de caer en mora lo que se traduce en mejores métricas de riesgo de sus portafolios.

Definiciones

Para el análisis se cuenta con una tabla con 622489 registros y 23 columnas. El conjunto de datos esta en forma de panel y reporta observaciones de originacion y desempeño de prestatarios para 50,000 créditos hipotecarios en los Estados Unidos sobre 60 periodos. El conjunto de datos es una selección aleatoria de datos del nivel de deuda hipotecario de los portafolios de hipotecas residenciales en USA.

Debido a esto se tendrá que hacer una transformación para tener por cliente una observación en función de su comportamiento crediticio.

2.1 Diccionario de las variables

El data set cuenta con las siguientes variables, a continuación se describen tanto en concepto como en naturaleza de las variables.

- id: ID del cliente
- Time: Tiempo de observación
- Orig time: Tiempo de originación
- First time: Tiempo para la primera observación
- Mat time: Tiempo de maduración
- Balance time: Saldo al tiempo de observación
- LTV time: Cociente loan to value al tiempo de observación en %
- Interest rate time: Tasa de interés al tiempo de observación en %
- HPI time: Índice de precio a la vivienda al tiempo de observación, base anual=100
- GDP time: Crecimiento del PIB al tiempo de observación en %
- UER time: Tasa de desempleo al tiempo de observación, en %

- REtype CO orig time: Condominio de bienes raíces =1, e.o.c.=0
- REtype PU orig time: Desarrollo de planeación urbana de bienes raíces=1, e.o.c.=0
- REtype SF orig time: Casa familiar =1, e.o.c.=0
- Investor orig time: Cliente inversionista =1, e.o.c.=0
- Balance orig time: Saldo al momento de la originación
- FICO orig time: Score Fico al momento de la originación, en %
- LTV orig time: Cociente loan to value al momento de la originación en %
- Interest Rate orig time: Tasa de interés al momento de la originación
- HPI orig time: Índice de precio a la vivienda, base anual =100
- Default time: Observación en mora al momento de la observación
- Payoff time: Observación en payoff al momento de la observación
- Status time: Impago (1), payoff (2), y no impago, no payoff (0) al momento de la observación

Palabra antes de ":"	Naturaleza de la Variable
ID del cliente	Categórica
Time	Continua
Orig time	Continua
First time	Continua
Mat time	Continua
Balance time	Continua
LTV time	Continua
Interest rate time	Continua
HPI time	Continua
GDP time	Continua
UER time	Continua
REtype CO orig time	Categórica
REtype PU orig time	Categórica
REtype SF orig time	Categórica
Investor orig time	Categórica
Balance orig time	Continua
FICO orig time	Continua
LTV orig time	Continua
Interest Rate orig time	Continua
HPI orig time	Continua
Default time	Categórica
Payoff time	Categórica
Status time	Categórica

2.2 Definición Variable Objetivo

La variable objetivo se desarrollan partiendo del supuesto de que "el desempeño futuro reflejará el desempeño pasado". Con base en este supuesto, se analiza el desempeño de cuentas abiertas previamente para predecir el desempeño de cuentas futuras. Para realizar este análisis, necesitamos recopilar datos de las cuentas abiertas durante un tiempo específico.

Dicho esto no es factible utilizar la información de la tabla de forma inmediata ya que se requiere un ajuste. Para seleccionar la ventana de tiempo se utilizan variables técnicas pero por limitaciones de la información solo haré una visualización del Bad Rate y de las cuentas según el periodo de maduración.

De este análisis podemos observar que una ventana de tiempo de 12 periodos serian suficientes para conocer a la mayoría de cuentas morosas que se tendrán ya que cerca de ese periodo el bad rate tiene un punto de inflexión y se estabiliza ademas

de aun poseer un buen volumen de cuentas. Tomar una ventana de tiempo mas grande causara perdida de observaciones pues no todas las cuentas tienen tantas observaciones.

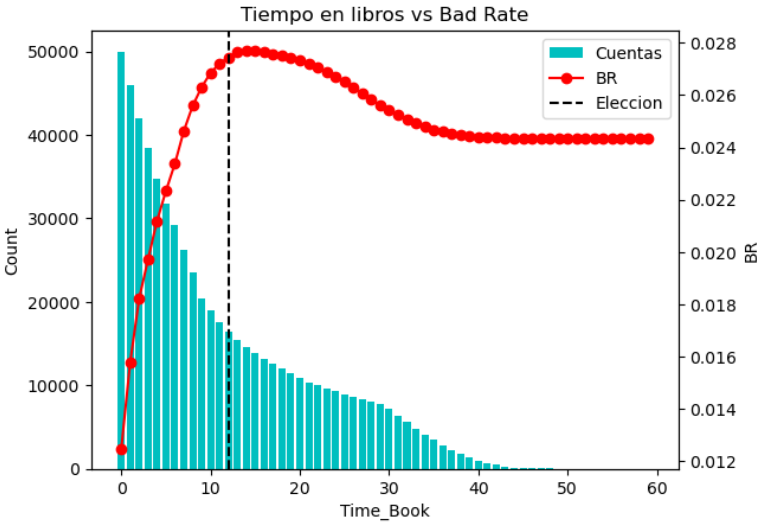

Figure 2.1: Evolución Variable Objetivo

Calidad De Datos

3.3 Duplicidad

Para evitar redundancia en la información es importante revisar que en bases se tenga el seguimiento del crédito por cliente. Para esta base no se poseen clientes duplicados (0%).

3.4 Completitud

En el mundo del análisis de datos y la estadística, los "valores missing" o valores faltantes se refieren a aquellos datos que están ausentes o no se encuentran registrados en un conjunto de datos. Aunque en un primer vistazo podríamos considerarlos un inconveniente, los valores missing desempeñan un papel esencial en la toma de decisiones informadas y en la obtención de resultados precisos en el análisis de datos. Para este set de datos no se tienen valores NaN. Por lo que no es necesario tomar alguna acción sobre el set.

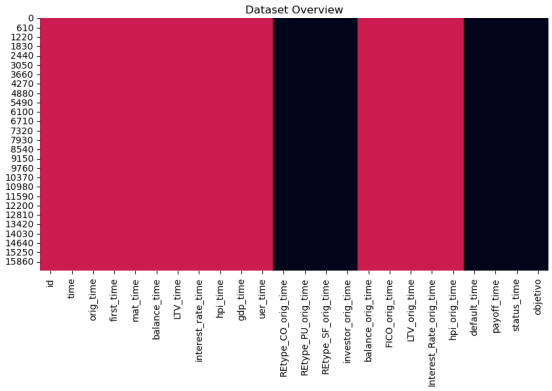

Figure 3.2: Heatmap de valores missing

3.5 Consistencia

Para las variables continuas y variables de id se validó que todas estén en formato float o int y que además no tuvieran registros fuera del rango de su definición. Para las variables categóricas se valido también variable por variable que estén en el mismo formato, algunas en float o int y otras en str.

3.6 Precisión

Después de la revisión de la consistencia de los datos se aprecia que todos contienen información precisa y util para continuar con proceso de limpieza de datos.

3.7 Normalización

Esta sección no aplica debido a que la tabla inicial posee solo variables numéricas o categóricas.

Análisis Exploratorio

Este análisis empieza con la visualización de la variable objetivo, de esta podemos observar que existe un desbalance notable y es común en créditos hipotecarios tener este tipo de distribuciones ya que las cuentas que se van a mora son muy pocas ademas de considerarse un producto con garantía.

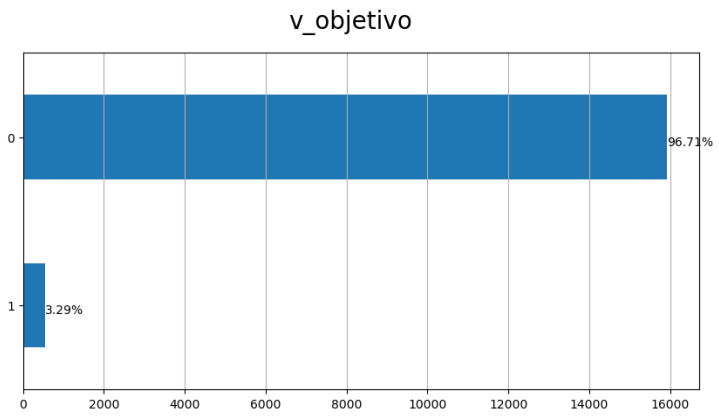

Figure 4.3: Distribución Variable Objetivo

El monto originado de un crédito puede ser un buen predictor de mora en una variedad de situaciones debido a varios motivos:

- Capacidad de Pago: Por lo general, los clientes con créditos de montos más altos pueden enfrentar mayores desafíos para hacer frente a los pagos si su capacidad financiera se ve comprometida. Un monto de crédito elevado puede requerir cuotas mensuales más altas, lo que aumenta la probabilidad de que un prestatario se atrase en los pagos en momentos de dificultades económicas.
- Efecto Psicológico: Los prestatarios que tienen montos de crédito significativos pueden sentir una mayor presión psicológica para cumplir con sus pagos a tiempo. Esto puede llevar a un comportamiento más cuidadoso y responsable en el manejo del crédito. Por otro lado, el estrés financiero causado por

un crédito grande puede llevar a un mayor riesgo de mora si el prestatario se encuentra en una situación financiera difícil.

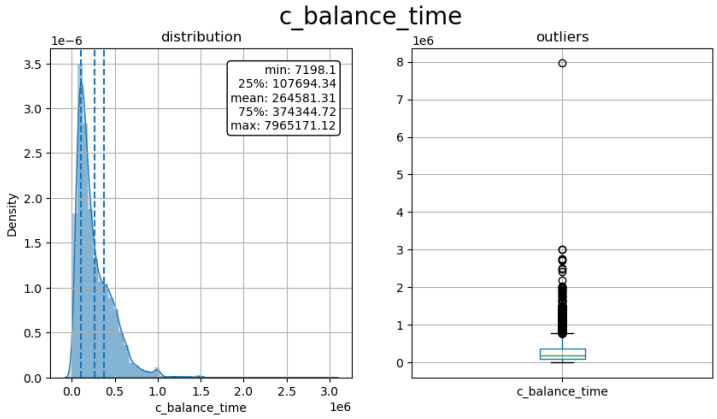

Figure 4.4:

El Loan to Value (LTV), que representa la relación entre el monto del préstamo y el valor del activo subyacente (como una propiedad), también puede ser un buen predictor de mora en préstamos hipotecarios y otros tipos de préstamos respaldados por activos.

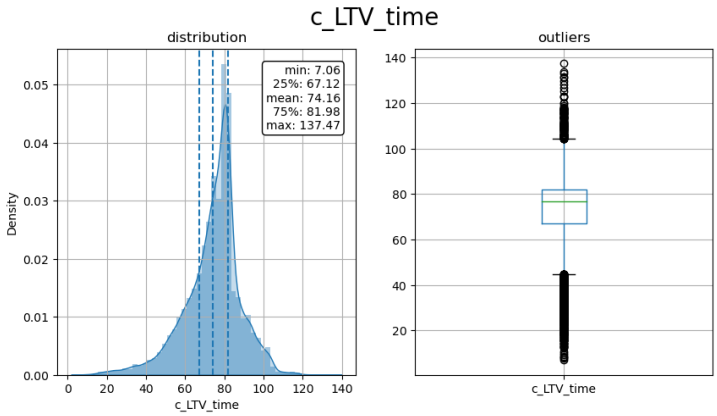

Figure 4.5:

La tasa de interés (o tasa de interés nominal) también es un factor crítico en la predicción de morosidad en préstamos y créditos.

- Ciclos Económicos: Durante períodos económicos difíciles con tasas de interés elevadas, es más probable que los prestatarios se enfrenten a dificultades financieras, lo que puede aumentar la probabilidad de mora. Las tasas de interés bajas pueden ser un amortiguador durante estas épocas.

- Costo del Endeudamiento: La tasa de interés determina el costo del endeudamiento para el prestatario. Cuanto más alta sea la tasa de interés, mayores serán los pagos mensuales requeridos para el préstamo. Si un prestatario enfrenta tasas de interés elevadas, es más probable que luche para realizar los pagos, lo que puede aumentar la probabilidad de mora.

- Calidad Crediticia: La tasa de interés que un prestatario califica puede ser indicativa de su calidad crediticia. Los prestatarios con tasas de interés más bajas a menudo tienen un historial crediticio más sólido, lo que puede estar relacionado con un menor riesgo de mora.

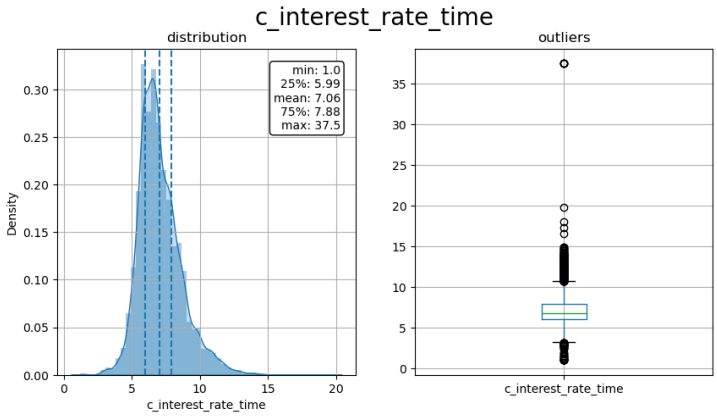

Figure 4.6:

El score de buró, también conocido como puntaje crediticio o credit score, es un predictor fundamental de morosidad en préstamos y créditos.

- Historial de Pagos: El score de buró se basa en el historial de pagos de un individuo, lo que incluye información sobre pagos puntuales, atrasos, morosidad y cuentas en colección. Este historial refleja la capacidad de un prestatario para cumplir con sus obligaciones financieras y es un indicador clave de riesgo de mora.

- Calidad Crediticia: El score de buró se calcula utilizando una variedad de factores, como el tiempo de historial crediticio, la utilización del crédito y la diversidad de cuentas. Un score de buró alto generalmente indica una calidad crediticia sólida y un menor riesgo de mora.

- Cumplimiento Regulatorio: En muchas jurisdicciones, las instituciones financieras están obligadas por regulaciones y leyes a utilizar el score de buró como parte de su proceso de toma de decisiones de crédito. Esto refuerza su importancia en la evaluación del riesgo de mora.

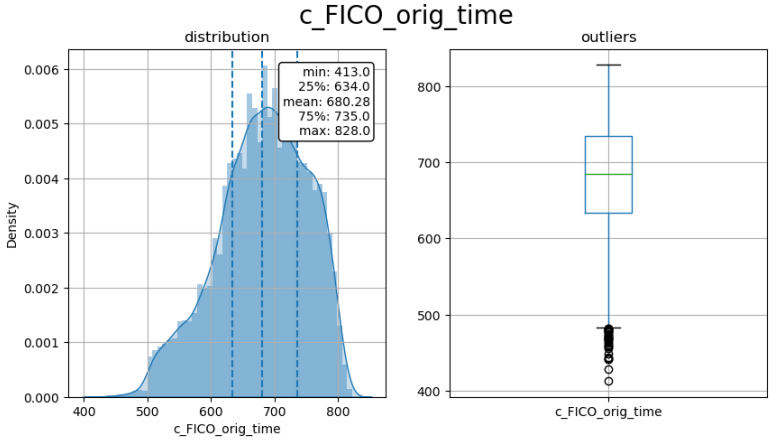

Figure 4.7:

El Índice de Precio a la Vivienda (HPI, por sus siglas en inglés, Home Price Index) es una medida importante en el análisis de morosidad y riesgo crediticio ya que refleja las tendencias y cambios en el valor de las propiedades inmobiliarias en una región o mercado específico. Cuando el valor de las propiedades aumenta, los propietarios tienen un activo más valioso que puede utilizarse como garantía en préstamos hipotecarios. Por lo tanto, un HPI en crecimiento tiende a ser un indicador positivo de la capacidad de los prestatarios para mantener sus pagos hipotecarios.

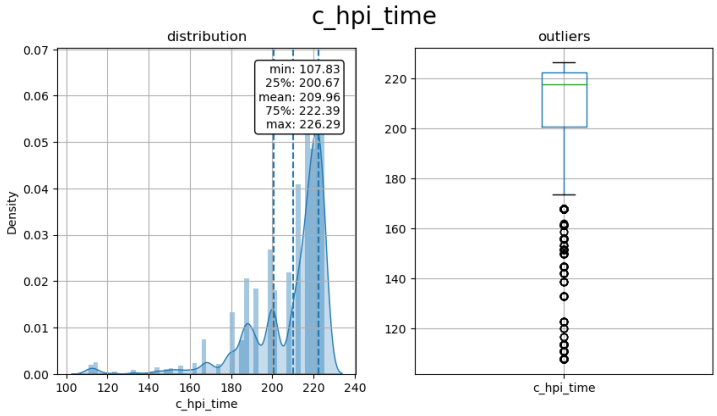

Figure 4.8:

La tasa de desempleo afecta directamente los ingresos de los individuos y hogares. Cuando la tasa de desempleo es alta o aumenta, puede haber una disminución en la capacidad de pago de los prestatarios, ya que es más probable que enfrenten

dificultades para mantener un flujo constante de ingresos. Esto puede aumentar la probabilidad de mora en préstamos y créditos.

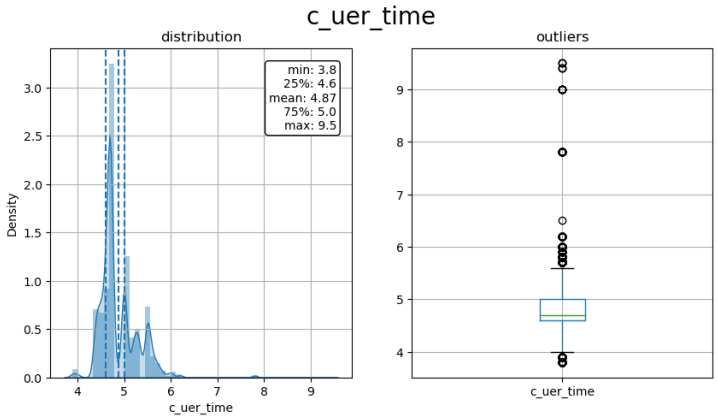

Figure 4.9:

De la matriz de correlaciones podemos observar que los únicos predictores que están bastante correlacionados son c hpi orig time y c hpi time ya que en concepto son lo mismo pero una evoluciona a medida que se amortiza el crédito.

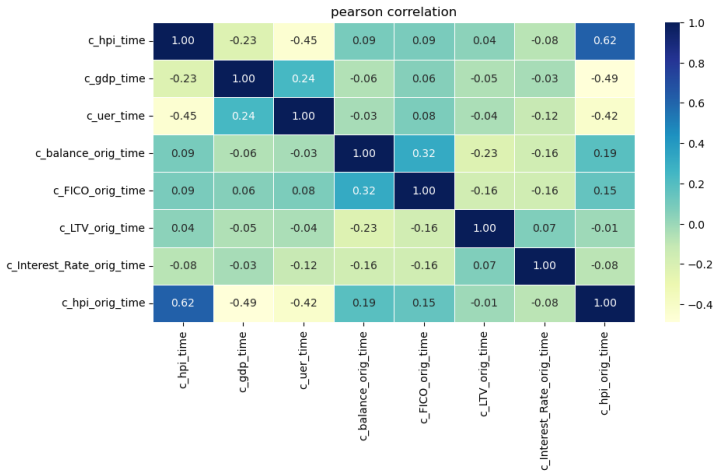

Figure 4.10:

Outliers

En esta sección abordo el tratamiento de valores atípicos utilizando dos técnicas multivariadas; Local Outlier Factor e Isolation Forest.

4.8 Local Outlier Factor

El LOF es un algoritmo de detección de anomalías utilizado para identificar puntos de datos que son atípicos en comparación con sus vecinos locales en un conjunto de datos multivariable. Proporciona una puntuación que mide la "anomalía" de cada punto de datos.

Ecuación del LOF:

La puntuación LOF para un punto de datos x_i se calcula de la siguiente manera:

$$LOF(x_i) = \frac{\sum_{x_j \in N(x_i)} \frac{\text{densidad}(x_j)}{\text{densidad}(x_i)}}{|N(x_i)|} \tag{4.1}$$

Donde:

- $LOF(x_i)$ es la puntuación LOF para el punto de datos x_i.
- $N(x_i)$ es el conjunto de vecinos locales de x_i.
- $\text{densidad}(x_i)$ es una medida de densidad local para x_i.

4.9 Isolation Forest

Isolation Forest es un algoritmo de detección de anomalías que se basa en la construcción de árboles de decisión aleatorios para aislar y identificar puntos de datos anómalos en un conjunto de datos.

El algoritmo Isolation Forest se basa en la idea de que los puntos de datos anómalos son más "fáciles" de aislar en árboles de decisión aleatorios. La puntuación de anomalía s(x)s(x) para un punto de datos xx se calcula como la profundidad promedio del nodo en el que xx se aísla en múltiples árboles dividido por la profundidad máxima promedio esperada en un conjunto de datos de puntos normales. En otras palabras:

$$s(x) = 2^{-\frac{E(h(x))}{c(n)}} \tag{4.2}$$

Donde:

- $s(x)$ es la puntuación de anomalía para el punto de datos x.
- $E(h(x))$ es la profundidad promedio del nodo en el que x se aísla en todos los árboles.
- $c(n)$ es una constante utilizada para normalizar la puntuación.

4.10 Implementación

La implementación de esto algoritmos fueron inicializados con un porcentaje de contaminación igual a 5%. Para Isolation forest se utilizaron 75 estimadores ya que en el paper hablan de una convergencia rápida por lo que no se requiere un numero alto de estimadores ademas de usar n-1 variables continuas. Para LOF se utilizo 10 vecinos y la métrica euclidiana como hiperparametros.

La selección del método de eliminación de outliers fue basado en el que menos elimine de la clase minoritaria ya que ejemplos de la clase mayoritaria hay suficientes por lo que preste mas atención a lo mencionado.

Esta comparativa se puede ver en el siguiente diagrama:

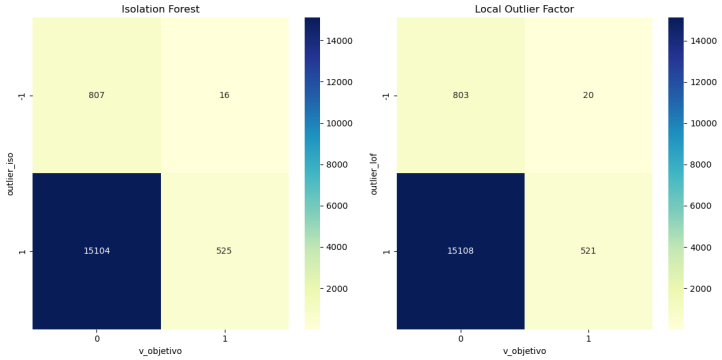

Figure 4.11:

Los siguientes plots indican el antes y después de utilizar el algoritmo de detección de anomalías Isolation Forest.

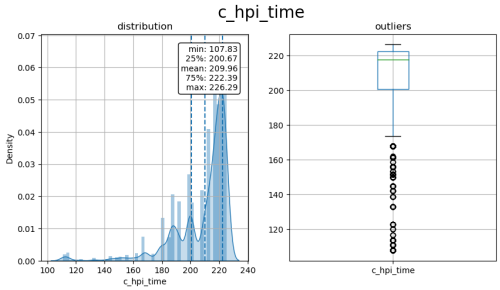

Figure 4.12: Antes del proceso

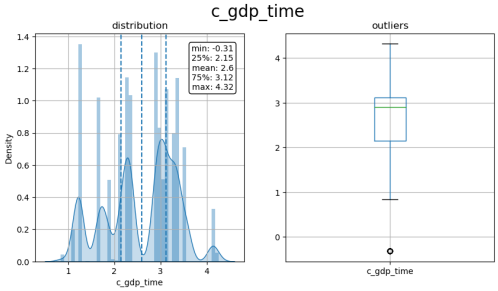

Figure 4.13: Después del proceso

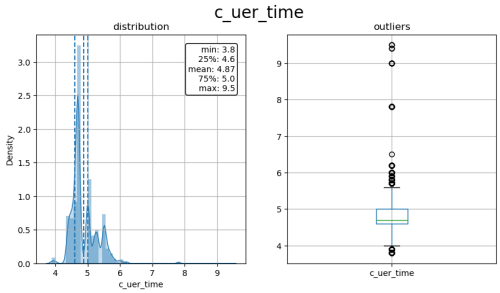

Figure 4.14: Antes del proceso

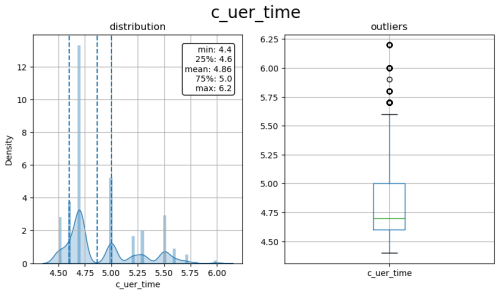

Figure 4.15: Después del proceso

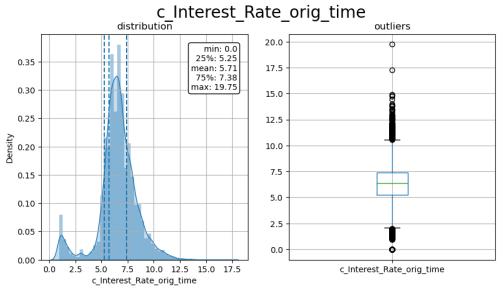

Figure 4.16: Antes del proceso

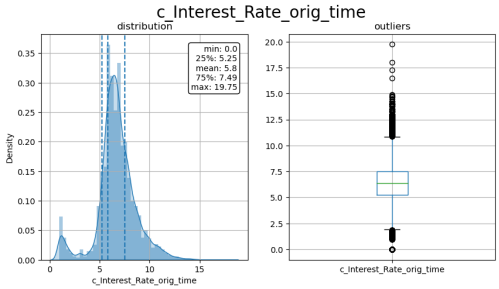

Figure 4.17: Después del proceso

Ingeniería de Variables

5.11 One-Hot encoding (Dummies)

Se decide codificar a las variables categóricas sin orden específico con el uso de dumificación. Dichas columnas son:

- 'v REtype CO orig time'
- 'v REtype PU orig time'
- 'v REtype SF orig time'
- 'v investor orig time'

5.12 Variables Continuas

El enfoque que le estoy dando a esta base es para un modelo de caja blanca ya que al tratarse de riesgo crediticio es útil contar con los siguientes puntos:

- Interpretabilidad: Los modelos de caja blanca son más interpretables que los modelos de caja negra. Esto significa que es más fácil comprender cómo se toman las decisiones y qué características son importantes en la predicción de default. Los reguladores y los responsables de la toma de decisiones pueden confiar más en un modelo cuyo funcionamiento pueden entender claramente.
- Explicación de Decisiones: Los modelos de caja blanca permiten explicar por qué un solicitante de crédito fue clasificado como riesgoso. Puedes identificar qué características o variables influyeron en la decisión, lo que es fundamental para prestar un servicio más transparente y justo.
- Cumplimiento Normativo: En muchas jurisdicciones, existen regulaciones que requieren que las instituciones financieras expliquen las decisiones crediticias a los solicitantes. Los modelos de caja blanca facilitan el cumplimiento de estas regulaciones al proporcionar una explicación transparente.

- Construcción de Confianza: Los modelos de caja blanca pueden ayudar a construir la confianza con los clientes y los reguladores. Los prestatarios pueden sentirse más cómodos si entienden cómo se evaluó su solicitud de crédito, y los reguladores pueden verificar y validar fácilmente el proceso de toma de decisiones.
- Facilitar la Revisión Humana: Los modelos de caja blanca permiten una revisión humana más efectiva. Los analistas de crédito pueden comprender rápidamente el razonamiento detrás de una decisión y realizar ajustes cuando sea necesario.
- Reducción de Riesgos Legales: Al proporcionar una explicación clara y documentada de las decisiones crediticias, los modelos de caja blanca pueden ayudar a las instituciones financieras a reducir el riesgo de demandas legales por parte de prestatarios descontentos.

Modelos

6.13 Re-balanceo de la Clase Minoritaria

El método SMOTE (Synthetic Minority Over-sampling Technique) es una técnica de procesamiento de datos ampliamente utilizada en el campo de la gestión de riesgos crediticios.

En el contexto de la gestión de riesgos de crédito, SMOTE se utiliza para abordar el desequilibrio en los conjuntos de datos. En muchos casos, las muestras de incumplimiento (clase minoritaria) son significativamente menos frecuentes en comparación con las muestras de pago puntual (clase mayoritaria). Este desequilibrio puede llevar a modelos de riesgo sesgados y menos precisos.

SMOTE resuelve este problema generando muestras sintéticas adicionales de la clase minoritaria. Estas muestras sintéticas se crean mediante la interpolación entre observaciones existentes, lo que equilibra el conjunto de datos y permite a los modelos de riesgo capturar mejor las señales relacionadas con el incumplimiento.

La aplicación de SMOTE en el contexto del riesgo de crédito puede proporcionar varios beneficios:

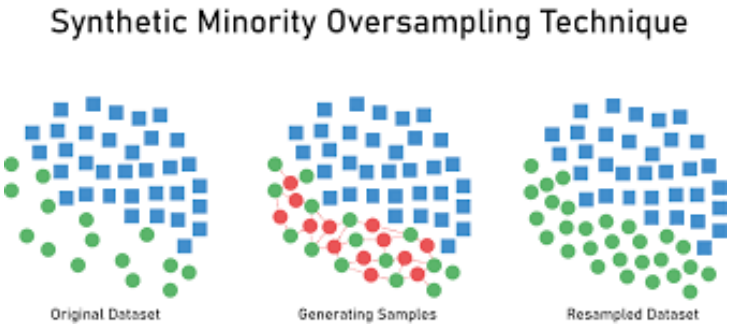

Figure 6.18: Smote

- Mejora de la precisión del modelo: Al equilibrar las clases en el conjunto de datos, los modelos de riesgo pueden aprender de manera más efectiva las características que distinguen a los prestatarios que tienen un mayor riesgo de incumplimiento.
- Reducción del sesgo: Los modelos entrenados en conjuntos de datos desequilibrados pueden verse sesgados hacia la clase mayoritaria. SMOTE ayuda a reducir este sesgo, lo que lleva a una evaluación más justa del riesgo.
- Identificación de riesgos ocultos: La generación de muestras sintéticas puede ayudar a los analistas de riesgo a identificar patrones y relaciones no evidentes en los datos originales, lo que puede ser crucial para la identificación temprana de riesgos de crédito.

6.14 Clasificadores

6.14.1 Recurrent neural network

6.14.2 Random Forest

Un Random Forest es un algoritmo de ensamble, se basa en la construcción y combinación de múltiples árboles de decisión para mejorar la precisión y la capacidad de generalización del modelo.

En un Random Forest, se crea un conjunto de árboles de decisión, donde cada árbol se construye independientemente utilizando un subconjunto aleatorio de los datos originales (muestreo de arranque o bootstrap). Además, en cada división de un nodo en un árbol, se selecciona un subconjunto aleatorio de características como candidatas para determinar la mejor división. Esta aleatoriedad en la construcción de los árboles contribuye a la diversidad del bosque.

La combinación de múltiples árboles de decisión permite mitigar el sobreajuste (overfitting) y mejorar la capacidad de generalización del modelo, ya que las decisiones individuales de cada árbol pueden estar sesgadas, pero al promediar o votar las predicciones de todos los árboles, se obtiene una predicción más robusta y precisa.

Para el entrenamiento del RF se utilizo una busqueda bayesiana y posteriormente se selecciono los mejores hiperparametros:

Table 6.1: Hiperparámetros

Parámetro	**Valor**
max depth	7
max features	log2
min samples leaf	0.1469834510705738
min samples split	0.07976378582764475

Para evaluar las métricas de ajuste del RF se utilizo validación cruzada obteniendo las siguientes métricas:

Table 6.2: Validación Cruzada

Métrica	**Promedio**	**SD**
Precision	0.93	0.00
Recall	0.96	0.00
F1	0.95	0.00
ROC AUC	0.61	0.05

6.14.3 Linear discriminant analysis (LDA)

Su objetivo principal es encontrar una combinación lineal de características que maximice la separación entre las clases en un conjunto de datos.

LDA se basa en ciertas suposiciones, como la normalidad de las distribuciones de las características y la igualdad de las matrices de covarianza de las clases.

Table 6.3: Hiperparámetros

Parámetro	**Valor**
shrinkage	0.5
solver	eigen

Para evaluar las métricas de ajuste del LDA se utilizo validación cruzada obteniendo las siguientes métricas:

Table 6.4: Validación Cruzada

Métrica	**Promedio**	**SD**
Precision	0.93	0.00
Recall	0.96	0.00
F1	0.95	0.00
ROC AUC	0.62	0.04

6.14.4 Quadratic Discriminant Analysis (QDA)

El Análisis Discriminante Cuadrático (QDA, Quadratic Discriminant Analysis) A diferencia del Análisis Discriminante Lineal (LDA), que busca encontrar una proyección lineal que maximice la separación entre las clases, el QDA asume que las clases tienen estructuras de covarianza diferentes y puede modelar las relaciones cuadráticas entre las características y las clases.

El QDA se basa en la suposición de que las diferentes clases tienen matrices de covarianza distintas. Esto significa que las clases pueden tener varianzas y correlaciones diferentes entre sus características. Mientras que el LDA asume matrices de covarianza iguales, el QDA permite una mayor flexibilidad al tratar con datos donde las estructuras de covarianza son diferentes entre las clases.

Table 6.5: Hiperparámetros

Parámetro	**Valor**
reg_param	0.002031537074096368

Para evaluar las métricas de ajuste del QDA se utilizo validación cruzada obteniendo las siguientes métricas:

Table 6.6: Validación Cruzada

Métrica	**Promedio**	**SD**
Precision	0.93	0.00
Recall	0.94	0.00
F1	0.94	0.01
ROC AUC	0.63	0.05

6.14.5 Gradient Boosting

Su objetivo principal es mejorar la precisión predictiva combinando múltiples modelos de aprendizaje débil para crear un modelo fuerte y altamente preciso.

El término "boosting" se refiere al proceso de mejorar el rendimiento del modelo mediante la corrección de los errores cometidos por los modelos anteriores. Cada nuevo modelo se entrena para capturar los errores residuales del conjunto de modelos existentes, lo que lo hace especialmente útil para enfocarse en ejemplos que son difíciles de clasificar o predecir.

El Gradient Boosting incluye mecanismos de regularización, como la limitación de la profundidad de los árboles y la introducción de parámetros de aprendizaje (learning rate), que ayudan a prevenir el sobreajuste del modelo.

Table 6.7: Hiperparámetros

Parámetro	**Valor**
learning_rate	0.08505956929719896
max_depth	7
max_features	log2
min_samples_leaf	0.011035606312960484
min_samples_split	0.011756734787241818
n_estimators	400

Para evaluar las métricas de ajuste del GB se utilizo validación cruzada obteniendo las siguientes métricas:

Table 6.8: Validación Cruzada

Métrica	**Promedio**	**SD**
Precision	0.93	0.01
Recall	0.96	0.00
F1	0.94	0.00
ROC AUC	0.57	0.06

6.15 Selección Final

El modelo que mejor se adapto a los datos y mejores métricas dio en Validación Cruzada fue el QDA. Ademas de que posee una curva ROC relativamente estable.

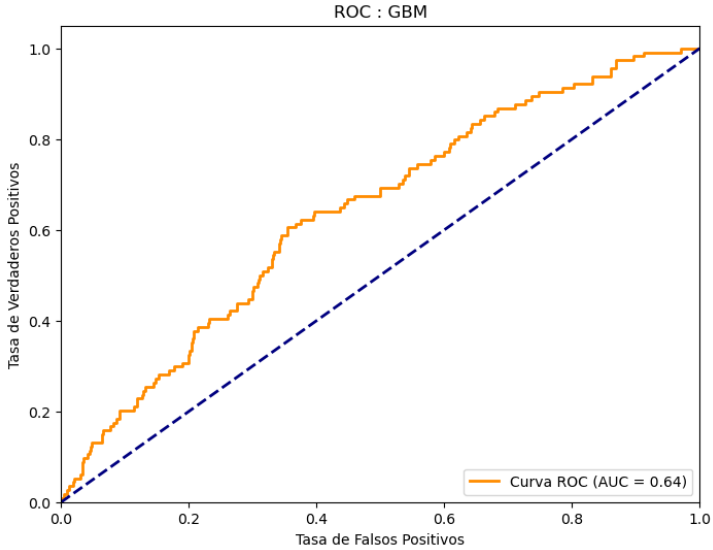

Figure 6.19: Conjunto De Test

Modelación No Supervisada

7.16 Introducción

La modelación no supervisada a diferencia de la modelación supervisada se trata de técnicas que a partir de N observaciones $(x_1, ..., x_N)$ de un vector aleatorio X con función de distribución conjunta $Pr(X)$ infiere propiedades de su función de probabilidad sin ayuda una referencia para comparar el grado de ajuste.

Con la modelación supervisada es claro la forma de medir que tan bien se esta ajustando el modelo a los datos y con ello juzgar o elegir el mejor método para predecir la variable objetivo. Es decir se puede medir la expected loss sobre la función de distribución conjunta.

La segmentación de datos se enfoca en encontrar patrones dentro del conjunto de observaciones. Las particiones son definidas de tal manera en que las observaciones pertenecientes a un clúster sean similares y distintas a otras observaciones fueras de esa agrupación.

Todos los métodos de segmentación de datos poseen una métrica de similitud para optimizar el numero de agrupaciones. Algunas de estas metricas son las siguientes:

7.16.1 Euclidiana

La distancia euclidiana entre el par de observaciones p y q se define como:

$$d(p, q) = \sqrt{(p_x - q_x)^2 + (p_x - q_x)^2)}$$

Esta forma de tomar la distancia permite dar mayor peso a aquellas observaciones.

7.16.2 Manhattan

Esta métrica también es conocida como distancia L_1 y se define como:

$$d(p,q) = \sum_{i=1}^{n} |(p_i - q_i)|$$

La forma de definir esta métrica permite hacerla menos influenciable a los outliers ya que no se eleva al cuadrado.

7.16.3 Jackknife

El coeficiente de correlación de Pearson es útil para medir la similitud entre variables aleatorias pero posee la desventaja de no ser robusta frente a outliers. Una forma de medir similitud usando el concepto de correlación es recurrir a metodos como Jackknife la cual calcula todos los posibles coeficientes de correlacion enre ds variables si se excluye cada vez una de las observaciones. El promedio de todas atenúan el efecto de outlier:

$$\theta_{(p,q)} = \frac{1}{n} \sum_{i=1}^{n} r_i$$

donde n es el numero de observaciones y r es el coeficiente de correlación de Pearson. Para obtener el efecto de los ourliers se calcula la correlacion de Jackknife y el que se obtiene empleando todas las observaciones. Esta diferencia es conocido como $BIAS$:

$$Bias = (n-1) \cdot (\theta - r)$$

7.16.4 Simple Matchinfg Coefficient

Para variables del tipo binario no tiene sentido aplicar las pasadas medidas de similitud. Por lo que las siguientes métricas están definidas para ente fin

$$SMC = \frac{Num.Coincidencias}{Num.totalatributos} = \frac{M_{00} + M_{01}}{M_{01} + M_{00} + M_{10} + M_{11}}$$

7.16.5 Indice Jaccard

El indice Jaccard tiene base en SMC bajo la modificacion de excluir el termini M_{00} en el cociente es decir:

$$Jacc = \frac{M_{01}}{M_{01} + M_{10} + M_{11}}$$

7.16.6 Distancia Coseno

El coseno del angulo que se forma entre dos vectores puede interpretarse como una memida de similitud, es decir si ambos vectores tienen la misma orientacion (angulo 0°) su coseno tomara el valor de 1.

$$Cos(p, q) = \frac{p \cdot q}{||p|| \cdot ||q||}$$

..

Si los vectores se normalizan restandoles la media se obtiene la correlación de Pearson.

7.16.7 Estandarización de variables

La escala que poseen las variables aleatorias afectan los resultados que se obtienen con el uso del clustering.Si una variable tiene una escala mayor que el resto determinara la similitud al comparar las observaciones. Por lo que escalar las variables asegura que todas las variables tendrán el mismo peso a la hora de calcular la matriz de similitudes.

La estandarización o también conocida como Z-Score busca que las variables tengan las propiedades de una normal estándar:

$$\mu = 0 \quad ; \quad \sigma = 1$$

A manera de ejemplo podemos pensar en el descenso del gradiente con variables en diferentes escalas esto ocasionara que ciertos pesos se actualicen de mas rápido que el resto desde que x_j juega en la actualización de este

$$\delta w_j = -n\frac{\partial J}{\partial w_j} = n\sum(t_i - o_i)x_j$$

Una alternativa a la normalización es $Min - Max$ esta estandarización permite escalas de $[0, 1]$

$$X_{Min-Max} = \frac{X - X_{min}}{X - X_{max}}$$

7.17 Reducción de Dimensión

7.17.1 Componentes Principales

Los componentes principales es una secuencia de proyecciones de los datos, mutuamente incorrelacionados y ordenados en varianza. Se puede pensar que los componentes principales son una variedad lineal aproximada a un conjunto de puntos en R^p.

Los pasos a seguir(de forma no rigurosa) para la obtención de las proyecciones son:

- **Paso 1:** Centrar los datos
$$X_c = X - \bar{X}$$
- **Paso 2:** Calcular la matriz de covarianza
$$S = \frac{1}{n-1} X_c^T \cdot X_c$$
- **Paso 3:** Calcular los autovectores y autovalores
$$S \cdot v_i = \lambda_i \cdot v_i$$
- **Paso 4:** Ordenar los autovectores y seleccionar los principales
- **Paso 5:** Formar las componentes principales
$$Z = X_c \cdot V_k$$

Aunque PCA es una técnica muy útil y ampliamente utilizada, como cualquier método, también tiene sus limitaciones y desventajas. Aquí algunas de las desventajas asociadas con el uso de PCA:

Desventajas de PCA	**Explicación**
Pérdida de interpretabilidad	Los componentes principales pueden ser difíciles de interpretar en términos de las variables originales.
Sensibilidad a valores atípicos	PCA puede ser influenciado por valores atípicos, afectando la identificación de componentes principales.
Requiere linealidad	La relación asumida entre las variables debe ser lineal, lo que puede no ser válido en todos los casos.
Dependencia de la escala	La escala de las variables puede afectar los resultados, dando más peso a variables con varianzas más altas.
Requiere datos completos	PCA no maneja naturalmente datos faltantes, requiriendo imputación o manejo previo.
No es robusto para datos categóricos	PCA está diseñado para variables numéricas y no se aplica directamente a datos categóricos.
Elección del número de componentes	La determinación de cuántos componentes principales retener es subjetiva y depende de criterios específicos.
Problema de la interpretación de componentes	Interpretar los componentes puede ser desafiante, especialmente en conjuntos de datos grandes.
No garantiza una mejora en todos los casos	La eficacia de PCA puede variar y no siempre garantiza una mejora al reducir la dimensionalidad.

Table 7.9: Desventajas de PCA

7.17.2 Multidimensional Scaling

Supongamos que se dispone de una matriz, D, $n \cdot n$ de distancias o disimilaridades entre los n elementos de un conjunto.

El objetivo del MDS es representar las distancias observadas mediante unas variables $y_1, ..., y_k$, donde $k < n$ tales que las distancias euclídeas entre las coordenadas de los elementos respecto a estas variables sean iguales (o lo más próximas posibles) a las distancias o disimilaridades de la matriz partida. Es decir se busca minimizar la funcion de estrés:

$$S_M(y_1, ..., y_k) = \sum_{i \neq i*} (d_{ii*} - \|y_i - y_{i*}\|)^2$$

Esto se conoce como mínimos cuadrados o escala de Kruskal-Shephard. La idea es encontrar una representación de dimensiones inferiores de los datos que preserve las distancias por pares lo mejor posible.

- **Interpretación no siempre intuitiva:** Las coordenadas en el espacio reducido pueden no tener una interpretación directa en términos de las variables originales.
- **Sensible a la elección de la medida de distancia:** El rendimiento de MDS puede depender de la elección de la medida de similitud o disimilitud utilizada.
- **Sensibilidad a valores atípicos:** Valores atípicos pueden influir en las distancias o similitudes y afectar la calidad del resultado de MDS.
- **Necesidad de datos completos:** MDS asume que la matriz de similitud o disimilitud está completamente especificada, lo que puede ser un desafío con datos faltantes.
- **Requiere elección del número de dimensiones:** La elección del número de dimensiones a menudo es subjetiva y puede afectar la interpretación de los resultados.
- **Puede no preservar la estructura global en algunos casos:** MDS no garantiza siempre preservar completamente la estructura global de las relaciones entre objetos.

7.18 Clusters

El análisis de conglomerados, también llamado segmentación de datos, tiene una variedad de objetivos. Todos se relacionan con agrupar o segmentar una colección de objetos en subconjuntos o "grupos", de modo que aquellos dentro de cada grupo estén más estrechamente relacionados entre sí que los objetos asignados a diferentes grupos.

Un objeto puede describirse mediante un conjunto de medidas o por su relación con otros objetos. Además, a veces el objetivo es organizar los grupos en una jerarquía natural.

7.18.1 K-Medias

El algoritmo K-means es uno de los métodos de agrupamiento de descenso iterativo más populares. Está destinado a situaciones en las que todas las variables son de tipo cuantitativo y distancia euclidiana al cuadrado es elegida como medida de disimilaridad.

El algorimo parte del supuesto de que poseemos una muestra :

$$X = \{x_1, x_2, \ldots, x_n\}$$

Se seleccionan Seleccionamos k puntos iniciales como centros de los clústeres, denotados como:

$$c_1, c_2, \ldots, c_k$$

Para cada punto x_i, calculamos la distancia euclidiana entre x_i y cada centro de clúster c_j.Asignamos x_i al clúster cuyo centro c_j está más cerca.

Para cada clúster, recalculamos el centro como el promedio de todos los puntos asignados a ese clúster.

$$c_j = \frac{1}{\text{Número de puntos en el clúster}} \sum_{\text{puntos asignados a } c_j} x_i$$

Repetimos hasta que se cumple algún criterio de convergencia, como la estabilidad en la asignación de puntos o la convergencia de los centros. El objetivo del algoritmo k-means es minimizar la función de costo, que se define como la suma de las distancias cuadradas entre cada punto y el centro de su clúster asignado:

$$J = \sum_{i=1}^{n} \sum_{j=1}^{k} \delta_{ij} \, \mathrm{dist}^2(x_i, c_j)$$

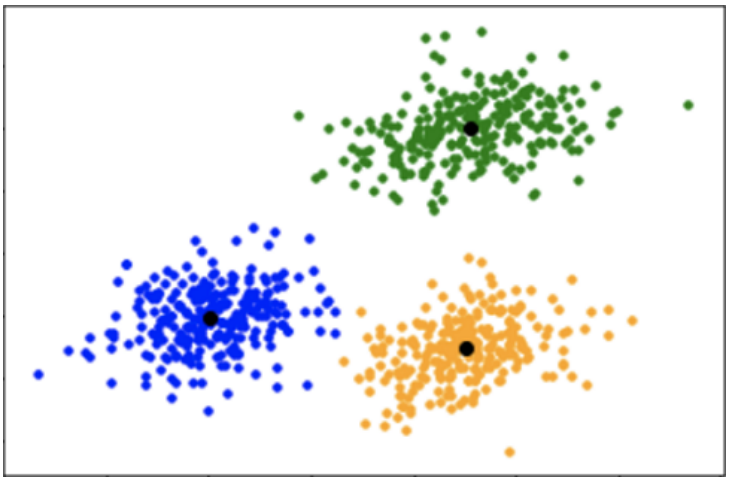

Figure 7.20:

El algoritmo k-means tiene varias desventajas y limitaciones:

- **Dependencia de la Inicialización:** El resultado final puede depender de la inicialización de los centroides.
- **Sensibilidad a Outliers:** La presencia de valores atípicos puede afectar significativamente los resultados.
- **Número de Clústeres (k) Predefinido:** El usuario debe especificar k de antemano, y la elección incorrecta puede conducir a resultados subóptimos.
- **Forma Geométrica Afecta el Resultado:** La forma geométrica de los clústeres influye en el rendimiento del algoritmo.
- **No Apto para Datos no Lineales:** El k-means asume clústeres convexos y puede tener dificultades con datos no lineales.
- **No Garantiza el Mínimo Global:** Converge a una solución, pero no garantiza el mínimo global de la función de costo.
- **Impacto de la Elección de la Métrica de Distancia:** La elección de la métrica de distancia puede afectar los resultados.
- **No Maneja Bien Clústeres de Diferentes Tamaños y Densidades:** Puede tener dificultades con clústeres de diferentes tamaños y densidades.

7.18.2 Mixturas Gaussianas

El procedimiento de agrupamiento de K-medias está estrechamente relacionado con el algoritmo EM para estimar un determinado modelo de mezcla gaussiana.

El $M - Step$ del algoritmo EM asigna "responsabilidades" para cada punto de datos en función de su densidad relativa bajo cada componente de la mezcla, mientras que el paso M vuelve a calcular los parámetros de densidad de los componentes en función de las responsabilidades actuales. Supongamos que especificamos K componentes de la mezcla, cada uno con una densidad gaussiana y una matriz de covarianza escalar $\sigma^2 I$.

El algorimo parte del supuesto de que poseemos una muestra :

$$X = \{x_1, x_2, \ldots, x_n\}$$

Se asume que los datos provienen de una combinación de k distribuciones gaussianas diferentes.Cada componente i en la mixtura está representado por una distribución gaussiana con parámetros específicos:

$$P(X|\theta_i) = \mathcal{N}(\mu_i, \Sigma_i)$$

Donde:

- μ_i es el vector de medias para el componente i.
- Σ_i es la matriz de covarianza para el componente i.

Cada componente tiene un peso asociado que representa la probabilidad de que un punto de datos pertenezca a ese componente.

$$\pi_i \geq 0 \quad , \quad \sum_{i=1}^{k} \pi_i = 1$$

La función de densidad de probabilidad conjunta para el modelo completo es una suma ponderada de las distribuciones gaussianas individuales:

$$P(X|\Theta) = \sum_{i=1}^{k} \pi_i \cdot \mathcal{N}(\mu_i, \Sigma_i)$$

$$P(X|\Theta) = \sum_{i=1}^{k} \pi_i \cdot \frac{1}{(2\pi)^{d/2}|\Sigma_i|^{1/2}} e^{-\frac{1}{2}(X-\mu_i)^T \Sigma_i^{-1}(X-\mu_i)}$$

Los parámetros del modelo se estiman maximizando la log-verosimilitud de los datos observados.

$$\Theta_{\text{MLE}} = \arg\max_{\Theta} \sum_{n=1}^{N} \log P(x_n|\Theta)$$

Calcular las probabilidades posteriores de pertenencia a cada componente para cada punto de datos, utilizando la regla de Bayes:

$$\gamma(z_{ni}) = \frac{\pi_i \cdot \mathcal{N}(\mu_i, \Sigma_i)}{\sum_{j=1}^{k} \pi_j \cdot \mathcal{N}(\mu_j, \Sigma_j)}$$

Actualizar los parámetros del modelo utilizando las probabilidades posteriores calculadas en el paso E:

- $\pi_i = \frac{1}{N} \sum_{n=1}^{N} \gamma(z_{ni})$
- $\mu_i = \frac{\sum_{n=1}^{N} \gamma(z_{ni}) \cdot x_n}{\sum_{n=1}^{N} \gamma(z_{ni})}$
- $\Sigma_i = \frac{\sum_{n=1}^{N} \gamma(z_{ni}) \cdot (x_n - \mu_i)(x_n - \mu_i)^T}{\sum_{n=1}^{N} \gamma(z_{ni})}$

Algunas desventajas de este algoritmo son:

- **Sensibilidad al Número de Componentes:** La elección incorrecta del número de componentes puede conducir a una mala representación del modelo.
- **Requiere Más Datos:** Puede requerir más datos que algunos otros algoritmos, especialmente cuando el número de dimensiones es alto.

Comentario Extra (No es una demostración Formal)

Si σ tiene un valor conocido en el modelo de mixturas gaussianas y tomamos $\sigma \to 0$, entonces en cierto sentido este algoritmo EM coincide con $K - medias$:

En el algoritmo K-means, cada clúster está representado por su centroide (μ). En el GMM, si dejamos que $\sigma \to 0$, el término exponencial se vuelve muy estrecho, haciendo que la función de densidad de probabilidad se aproxime a una función delta de Dirac. El componente del GMM se aproxima a una masa puntual en la media μ_i.

En el límite cuando $\sigma \to 0$, la función de densidad del MG para una sola componente se convierte en:

$P(X|\theta_i) \to \delta(X - \mu_i)$ donde δ es la función delta de Dirac.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2} \quad \text{con } \mu = 0$$

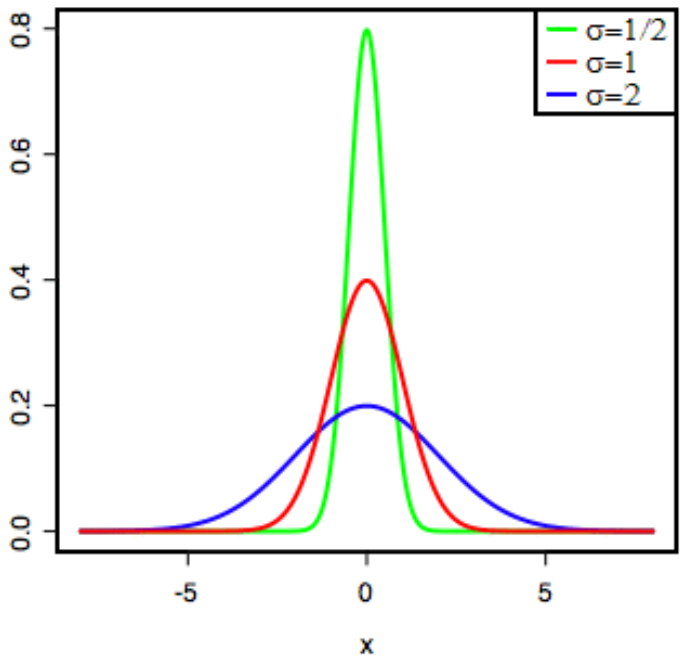

Figure 7.21:

Ahora, observemos la fase E y la fase M del algoritmo EM para GMM en este límite:

Las responsabilidades $\gamma(z_{ni})$ se convierten en 1 para el componente (i) que maximiza la probabilidad. Dado que la probabilidad se concentra alrededor de μ_i a medida que $\sigma \to 0$, cada punto se asigna esencialmente a la media más cercana μ_i.

Las ecuaciones de actualización para μ_i se convierten en las mismas que en K-means, donde la media se actualiza al centroide de los puntos asignados al clúster.

En resumen, a medida que $\sigma \to 0$, el MG se comporta como K-means porque el componente del MG se concentra cada vez más alrededor de su media, pareciéndose a una masa puntual. La fase E asigna puntos a la media más cercana, y la fase M actualiza las medias de manera similar a K-means.

7.18.3 DBSCAN

Es un algoritmo de agrupamiento que se destaca por su capacidad para identificar clústeres de forma arbitraria y manejar puntos de datos que no pertenecen a ningún clúster.

DBSCAN agrupa puntos de datos basándose en su densidad local. La densidad se mide contando el número de puntos dentro de un área determinada alrededor de un punto central.

Parametros Clave:

- Epsilon (ϵ): Define el radio alrededor de un punto central. Puntos dentro de este radio son considerados vecinos.
- MinPts: Representa el número mínimo de puntos dentro del radio ϵ para que un punto sea considerado núcleo y, por lo tanto, forme parte de un clúster.

Ventajas:

- **Manejo de Formas Arbitrarias:** Puede identificar clústeres de formas arbitrarias y no está limitado por la forma esférica.
- **Resistente al Ruido:** Puede manejar puntos de datos que no pertenecen a ningún clúster.
- **No Requiere Especificación de Número de Clústeres:** No es necesario especificar el número de clústeres de antemano.
- **Sensible a la Densidad:** Ajusta automáticamente a la densidad local de los datos.

Desventajas:

- **Sensibilidad a la Densidad y Escala:** DBSCAN puede ser sensible a la densidad de los datos y a la escala de las características, lo que puede afectar la identificación de clústeres en conjuntos de datos con densidades variables.
- **Dificultad con Clústeres de Densidades Variadas:** Puede tener dificultades para identificar clústeres de formas complejas o tamaños diferentes si la densidad varía significativamente en el espacio de características.
- **Requiere Ajuste de Parámetros:** La elección de los parámetros (ε y `MinPts`) puede ser crítica y depende del conjunto de datos específico, lo que puede requerir ajuste manual.
- **No Maneja Bien Datos de Alta Dimensión:** DBSCAN puede enfrentar dificultades en conjuntos de datos de alta dimensión debido al fenómeno conocido como la "maldición de la dimensionalidad".
- **No Funciona Bien con Clústeres de Forma No Convexa:** Puede tener dificultades para identificar clústeres de forma no convexa debido a su enfoque basado en conectividad.
- **Problema con la Elección de ε en Conjuntos de Datos de Densidad Variable:** En conjuntos de datos con variación en la densidad, la elección de ε puede ser complicada y puede afectar significativamente los resultados del algoritmo.

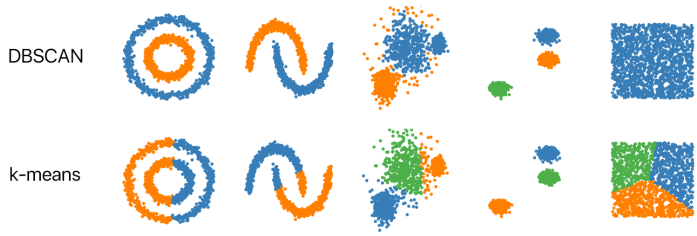

Figure 7.22:

7.18.4 Perfilamiento y Estabilidad

El índice de estabilidad de población (PSI) se utiliza para medir la estabilidad de los clusters a lo largo del tiempo o en diferentes segmentos de datos. Para calcular el PSI, se pueden seguir los siguientes pasos:

Definiciones:

- p_i: Proporción de elementos en el cluster i en la población de referencia.
- q_i: Proporción de elementos en el cluster i en la población objetivo.

Fórmula del PSI:

El PSI se puede calcular utilizando la siguiente fórmula:

$$PSI = \sum_{i=1}^{k} (p_i - q_i) \cdot \ln\left(\frac{p_i}{q_i}\right)$$

donde k es el número de clusters.

Interpretación:

El PSI se interpreta como una medida de la discrepancia entre las proporciones de elementos en los clusters de la población de referencia y la población objetivo. Un valor alto de PSI indica una mayor discrepancia y, por lo tanto, una menor estabilidad en los clusters.

Prueba de Tukey para Varianza (ANOVA)

La prueba de Tukey, también conocida como la prueba de Tukey HSD (Honest Significant Difference), se utiliza para realizar comparaciones múltiples entre grupos después de realizar un análisis de varianza (ANOVA). El objetivo es identificar qué pares de grupos tienen diferencias significativas en sus medias.

Procedimiento

1. **Realizar ANOVA:** Antes de aplicar la prueba de Tukey, se realiza un análisis de varianza para determinar si hay diferencias significativas entre las medias de los grupos.
2. **Estadístico de la Prueba de Tukey:** El estadístico de la prueba de Tukey se calcula como sigue:

$$Q = \frac{\bar{X}_i - \bar{X}_j}{\sqrt{MSE/n}}$$

donde $\bar{X}_i$ y $\bar{X}_j$ son las medias de los grupos i y j, MSE es el error cuadrático medio del ANOVA y n es el número de observaciones en cada grupo.

3. **Comparación de Estadísticos con Criterio de Significancia:** Se comparan los estadísticos Q calculados con un criterio de significancia, como el cuantil de la distribución de Studentized range ($q_{\alpha,k,\nu}$).

4. **Identificación de Diferencias Significativas:** Si $|Q| > q_{\alpha,k,\nu}$, se concluye que hay una diferencia significativa entre las medias de los grupos i y j.

Fórmula de Estadístico de la Prueba de Tukey

$$Q = \frac{\bar{X}_i - \bar{X}_j}{\sqrt{MSE/n}}$$

Criterio de Significancia

El cuantil de la distribución de Studentized range ($q_{\alpha,k,\nu}$) se utiliza para comparar con los estadísticos Q, donde α es el nivel de significancia, k es el número total de grupos y ν es el número de grados de libertad del error.

7.18.5 Caso Practico: Proyecto

En el ámbito financiero, la evaluación del riesgo de crédito desempeña un papel fundamental para las instituciones bancarias y financieras. La capacidad de predecir de manera precisa la probabilidad de incumplimiento de un cliente es esencial para tomar decisiones informadas en la concesión de préstamos y la gestión de carteras. El aprendizaje no supervisado emerge como una herramienta poderosa en este contexto, permitiendo a las entidades financieras explorar patrones y relaciones complejas en los datos sin depender de etiquetas previas.

A diferencia del aprendizaje supervisado, donde el modelo se entrena con datos etiquetados, el aprendizaje no supervisado se basa en la capacidad del algoritmo para identificar patrones y estructuras subyacentes en conjuntos de datos no etiquetados. En el contexto del riesgo de crédito, este enfoque ofrece la posibilidad de descubrir relaciones no evidentes entre variables, identificar segmentos de clientes con perfiles similares y mejorar la precisión en la evaluación del riesgo crediticio.

Este enfoque innovador no solo permite a las instituciones financieras optimizar sus estrategias de concesión de préstamos, sino que también brinda la oportunidad de adaptarse de manera dinámica a los cambios en el comportamiento del cliente y en las condiciones económicas. En esta introducción, exploraremos cómo el aprendizaje no supervisado se ha convertido en una herramienta clave en el análisis de riesgo de crédito, ofreciendo nuevas perspectivas y mejorando la capacidad de anticiparse a posibles riesgos.

Para el análisis se cuenta con una tabla con 15629 registros y 8 columnas numéricas. El conjunto de datos ya esta limpio ya que es que se uso en el modulo 2. El conjunto de datos es una selección aleatoria de datos del nivel de deuda hipotecario de los portafolios de hipotecas residenciales en USA. Debido a esto se tendrá que hacer una transformación para tener por cliente una observación en función de su comportamiento crediticio.

Modelación Mixturas Gaussianas

Para el desarrollo del modelo se utilizó el BIC, comparando el número de componentes y el tipo de matriz de covarianza, en este caso el algoritmo tiene su punto de inflexión usando una matriz tipo full (cada componente tiene su propia matriz de covarianza) y 8 componentes. Aun así este ajuste no daba buenos resultados en las pruebas de tuckey ya que no pasaban las pruebas y volvía inmanejable por lo que se probó con modelos más sencillos reduciendo el número de componentes pero manteniendo el ajuste Full

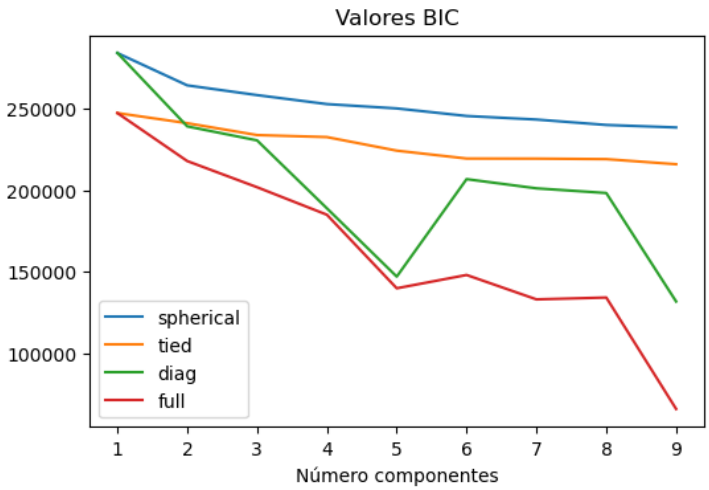

Figure 7.23:

Las variables que resultaron significativas dentro de los clusters son:

- c LTV orig time : Cociente loan to value al momento de originar
- c hpi time : Indice de precio a la vivienda
- c FICO orig time : Score Fico al momento de la originación
- c Interest Rate orig : Tasa de interés al tiempo de observación
- c uer time : Tasa de desempleo al tiempo

Para la visualización de datos se usaron 3 técnicas debido a que la tradicional PCA no tuvo resultados por lo que decidí investigar algunas técnicas que se basen mas en estructuras mas complejas

- **Principal Component Analysis (PCA):**
  - **Descripción:** PCA es una técnica clásica de reducción de dimensionalidad que transforma un conjunto de datos original en componentes principales no correlacionados, capturando la mayor varianza en los datos.
  - **Uso Común:** Efectivo para eliminar redundancia en datos altamente correlacionados y reducir la dimensionalidad.
- **t-Distributed Stochastic Neighbor Embedding (t-SNE):**
  - **Descripción:** t-SNE es una técnica no lineal que preserva la similitud entre pares de puntos, adaptándose bien a la visualización de datos en conjuntos de baja dimensión y capturando estructuras no lineales.
  - **Uso Común:** Útil para revelar estructuras complejas y relaciones no lineales en conjuntos de datos.
- **Spectral Embedding:**
  - **Descripción:** Spectral Embedding utiliza información de eigenvalores y eigenvectores para mapear datos a un espacio de menor dimensión, capturando relaciones lineales y no lineales.
  - **Uso Común:** Aplicado en conjuntos de datos no linealmente separables con estructuras complejas, comúnmente utilizado en problemas de clustering y visualización de datos.

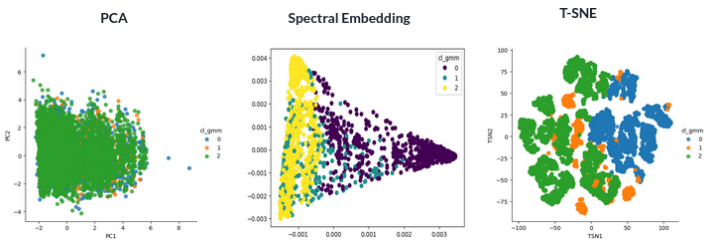

Figure 7.24:

- Segmento Base Poseen scores ligeramente superior a la población y el rendimiento que proporcionan esta por debajo de la media poseyendo una tasa de desempleo ligeramente por encima lo que se podría traducir en población sin empleo fijo.
- Segmento Vulnerable debido a que poseen Score de Fico por debajo de la media y poseen una tasa de interés alta por lo que se traduce población que puede dejar de pagar
- Segmento estándar poseen medidas similares a la población general.

Estabilidad de los Clusters

La estabilidad de los clusters es un aspecto crítico en el análisis de clustering, y se evalúa mediante diversas métricas, siendo una de ellas el índice de estabilidad. En este caso el valor de psi se acerca a 0.00008, indica una alta estabilidad de los clusters. Este índice se calculo comparando la estabilidad de los grupos encontrados en diferentes ejecuciones(train y test).

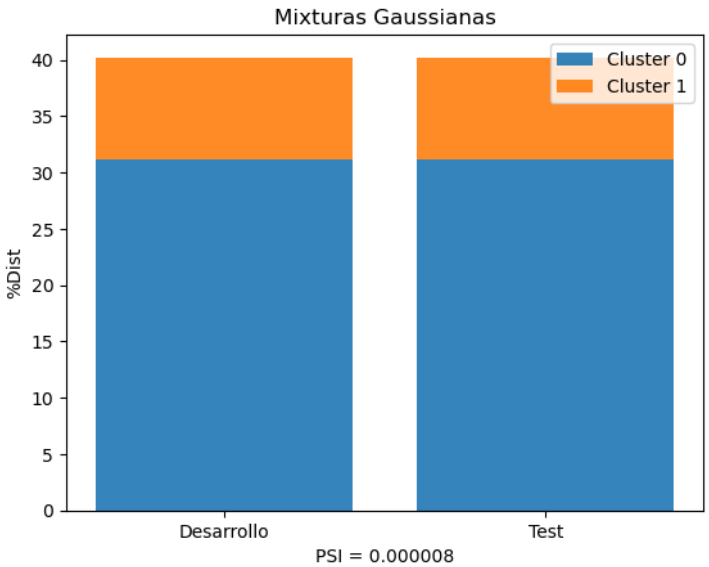

Figure 7.25:

Estrategia

Dado que las campañas son limitadas en recursos se podrían enfocar únicamente al cluster 1 ya que poseen tasas de interés altas y un score no muy bueno por lo que podrían caer en riesgo de incumplimiento en caso de eventos macroeconómicos graves si bajaramos la tasa del cluster 1 a condiciones similares al cluster 2 de creceriamos en 3% la mora total del producto.

Deep Learning

8.19 Introducción

Una red neuronal es un procesador distribuido masivamente en paralelo que tiene una propensión natural a almacenar conocimiento experiencial y poniéndolo a disposición para su uso. Se parece al cerebro en dos aspectos.

- El conocimiento lo adquiere la red a través de un aprendizaje proceso.
- Se utilizan fuerzas de interconexión conocidas como pesos sinápticos.

para almacenar el conocimiento el aprendizaje es un proceso mediante el cual los parámetros libres (es decir,pesos sinápticos y niveles de sesgo) de una red neuronal se adaptan a través de un proceso continuo de estimulación por parte del medio ambiente en el que está integrada la red. El tipo de aprendizaje está determinado por la forma en que se producen los cambios de parámetros.

La forma de aprendizaje supone la disponibilidad de un conjunto de datos etiquetado de entrenamiento compuesto por N observaciones:

$$(X, Y)$$

8.20 Funciones de activación

Las funciones de activación juegan un papel fundamental en las redes neuronales porque introducen no linealidades en el modelo, permitiendo así que la red neuronal aprenda y represente relaciones complejas entre las entradas y las salidas:

1. **No linealidad:** Sin funciones de activación, una red neuronal sería simplemente una combinación lineal de las entradas, lo que limitaría su capacidad para modelar datos no lineales. Las funciones de activación como la sigmoide, ReLU y tangente hiperbólica introducen no linealidades en las salidas de las

neuronas, permitiendo a la red capturar patrones y relaciones más complejas en los datos.

2. **Representación de funciones complejas:** Las funciones de activación permiten a una red neuronal representar funciones complejas y no lineales. Esto es crucial para tareas como la clasificación de imágenes, el procesamiento de lenguaje natural y la predicción de series temporales, donde las relaciones entre las entradas y las salidas pueden ser altamente no lineales y difíciles de modelar con métodos lineales.

3. **Capacidad de aprendizaje:** Las funciones de activación ayudan a mejorar la capacidad de aprendizaje de una red neuronal al permitir que aprenda y adapte sus parámetros a datos de entrenamiento variados y complejos. La introducción de no linealidades mediante funciones de activación evita que la red se quede atrapada en soluciones lineales simples y le permite explorar un espacio de funciones más rico y diverso.

4. **Diferenciabilidad:** Muchas funciones de activación utilizadas en la práctica, como la sigmoide y la tangente hiperbólica, son diferenciables en todo su dominio. Esto es crucial para el entrenamiento de redes neuronales mediante técnicas de optimización basadas en el gradiente, como el descenso del gradiente estocástico (SGD), ya que requieren el cálculo de gradientes para actualizar los pesos de la red de manera iterativa.

La forma matemática de estas funciones es la siguiente:

- Función Sigmoide:

$$f(x) = \frac{1}{1 + e^{-x}}$$

- Función ReLU (Rectified Linear Unit):

$$f(x) = \max(0, x)$$

- Función Leaky ReLU:

$$f(x) = \begin{cases} x, & \text{si } x > 0 \\ ax, & \text{si } x \leq 0 \end{cases}$$

  donde a es un valor pequeño positivo, generalmente cercano a 0.

- Función Tangente Hiperbólica (Tanh):

$$f(x) = \tanh(x)$$

- Función Softmax (para la capa de salida en problemas de clasificación):

$$f(x)_i = \frac{e^{x_i}}{\sum_{j=1}^{N} e^{x_j}}$$

  donde N es el número de clases y x_i es la entrada a la neurona de la clase i.

- Función Softplus:

$$f(x) = \ln(1 + e^x)$$

8.21 Explosión y desvanecimiento del gradiente

El desvanecimiento del gradiente y la explosión del gradiente son problemas comunes que pueden ocurrir durante el entrenamiento de redes neuronales profundas. Estos problemas surgen debido a la propagación del gradiente a través de múltiples capas de la red.

Desvanecimiento del gradiente:

El desvanecimiento del gradiente ocurre cuando los gradientes se vuelven muy pequeños a medida que se propagan hacia atrás a través de las capas de la red. Esto puede hacer que los pesos de las capas iniciales de la red no se actualicen significativamente durante el entrenamiento, lo que dificulta que la red aprenda correctamente.

Matemáticamente, el desvanecimiento del gradiente se puede expresar como la disminución exponencial de la magnitud del gradiente a medida que se propaga hacia atrás a través de las capas. Por ejemplo, para una red neuronal con L capas, la propagación hacia atrás del gradiente se puede expresar como:

$$\frac{\partial Loss}{\partial W_i} = \prod_{l=1}^{L} \frac{\partial}{\partial W_i^{(l)}}$$

donde W_i representa los pesos de la capa i, y $W_i^{(l)}$ representa los pesos de la capa i en la iteración l.

Explosión del gradiente:

La explosión del gradiente ocurre cuando los gradientes se vuelven demasiado grandes a medida que se propagan hacia atrás a través de las capas de la red. Esto puede provocar inestabilidad numérica durante el entrenamiento e impedir que la red converja a una solución óptima.

Matemáticamente, la explosión del gradiente se puede expresar como un aumento exponencial de la magnitud del gradiente a medida que se propaga hacia atrás a través de las capas. Por ejemplo, para una red neuronal con L capas, la propagación hacia atrás del gradiente se puede expresar como:

$$\frac{\partial Loss}{\partial W_i} = \prod_{l=1}^{L} \frac{\partial}{\partial W_i^{(l)}}$$

donde W_i representa los pesos de la capa i, y $W_i^{(l)}$ representa los pesos de la capa i en la iteración l.

8.22 Funciones de costo en redes neuronales

Las funciones de costo, también conocidas como funciones de pérdida o funciones objetivo, son medidas que se utilizan para evaluar qué tan bien está funcionando una red neuronal en términos de la discrepancia entre las predicciones del modelo y los valores reales de los datos de entrenamiento. Estas funciones juegan un papel crucial en el proceso de entrenamiento de la red, ya que guían al algoritmo de optimización para ajustar los pesos de la red con el objetivo de minimizar la pérdida.

Importancia de las funciones de costo:

Las funciones de costo son esenciales en el aprendizaje supervisado porque proporcionan una forma de cuantificar el rendimiento del modelo y guiar el proceso de optimización para mejorar este rendimiento. Al elegir una función de costo adecuada, los desarrolladores pueden adaptar el modelo a la naturaleza específica de los datos y la tarea en cuestión.

Tipos de funciones de costo:

Existen diferentes tipos de funciones de costo, cada una diseñada para abordar diferentes tipos de problemas y distribuciones de datos. Algunas de las funciones de costo más comunes incluyen:

- **Error cuadrático medio (MSE):** Esta función de costo calcula el promedio de los cuadrados de las diferencias entre las predicciones del modelo y los valores reales. Es adecuada para problemas de regresión donde se desea minimizar la discrepancia entre las predicciones y los valores reales.
- **Entropía cruzada binaria:** Utilizada en problemas de clasificación binaria, la entropía cruzada binaria mide la discrepancia entre las predicciones de

probabilidad del modelo y las etiquetas verdaderas. Es especialmente útil cuando las etiquetas son binarias (0 o 1).

- **Entropía cruzada categórica:** Similar a la entropía cruzada binaria, pero aplicada a problemas de clasificación multiclase, donde las etiquetas son categóricas y se representan como vectores one-hot.
- **Entropía cruzada categórica ponderada:** Una variante de la entropía cruzada categórica que asigna pesos diferentes a las clases para abordar desequilibrios de clases en los datos de entrenamiento.
- **Pérdida de charla (Hinge loss):** Utilizada en problemas de clasificación binaria y basada en márgenes, la pérdida de charla penaliza las predicciones incorrectas que no cumplen con un margen mínimo. Es comúnmente utilizada en problemas de clasificación con máquinas de vectores de soporte (SVM).

Selección de la función de costo:

La elección de la función de costo adecuada depende del tipo de problema, la distribución de los datos y las características específicas del conjunto de datos. Es importante seleccionar una función de costo que se alinee con los objetivos y requisitos del problema en cuestión, así como considerar el impacto de cualquier desequilibrio de clases o sesgos en los datos.

8.23 Backpropagation

El algoritmo de backpropagation fue introducido originalmente en la década de 1970, pero su importancia no se apreció del todo hasta un famosos Documento de 1986 por David Rumelhart, Geoffrey Hinton, y Ronald - Williams.

El backpropagation es un algoritmo clave en el entrenamiento de redes neuronales, utilizado para ajustar los pesos de la red con el objetivo de minimizar una función de pérdida.

Para minimizar la función de costo, es necesario determinar qué pesos y sesgos ajustar. Calcular el gradiente con respecto a los parámetros puede ayudarnos a hacer precisamente eso, ya que por definición el gradiente es un vector de derivadas parciales de $C(w_1, w_2, \ldots, w_h, b_1, \ldots, b_i)$. Como recordamos,las derivadas miden el cambio en la salida de una función con respecto a su entrada. El gradiente de la función de costo nos indica en qué dirección $C(w_1, w_2, \ldots, w_h, b_1, \ldots, b_i)$ disminuye más rápidamente. Esto suele conocerse como Descenso de Gradiente. Con cada época, la máquina converge hacia el mínimo local. La diferenciación automática

combina la regla de la cadena con una gran potencia computacional para derivar el gradiente de un modelo potencialmente masivo y complejo. En reversa, este algoritmo es conocido como Retropropagación. La retropropagación se realiza recursivamente a través de cada capa individual de la red neuronal.

Podemos determinar cuán sensible es la función de costo a los cambios en un solo peso. Comenzando desde la salida, podemos aplicar la regla de la cadena a cada capa de activación. Para un peso entre la capa oculta y la capa de salida, nuestra derivada es:

$$\frac{\delta C_k}{\delta w^L} = \frac{\delta z^L}{\delta w^L}\frac{\delta a^L}{\delta z^L}\frac{\delta C_k}{\delta a^L}$$

Con la definición de las funciones, podemos resolver fácilmente las derivadas parciales:

$$\frac{\delta C_k}{\delta a^L} = 2(a^L - y)$$

$$\frac{\delta a^L}{\delta z^L} = \sigma'(z^L)$$

$$\frac{\delta z^L}{\delta w^L} = a^{L-1}$$

$$\frac{\delta C_k}{\delta w^L} = a^{L-1}\sigma'(z^L)2(a^L - y)$$

Este método se itera a través de cada peso, número de activación y sesgo en el sistema. Anteriormente, calculamos la derivada de una función de costo particular con una variable. Sin embargo, para tener en cuenta cada peso en esa capa, se toma el promedio de las derivadas:

$$\frac{\delta C}{\delta w^L} = \frac{1}{n}\sum_{k=0}^{n-1}\frac{\delta C_k}{\delta w^L}$$

De manera similar, podemos calcular la sensibilidad de la función de costo con respecto a un solo sesgo entre la capa oculta y la capa de salida, y la derivada que tiene en cuenta cada sesgo en una capa:

$$\frac{\delta C}{\delta b^L} = \frac{\delta z^L}{\delta b^L}\frac{\delta a^L}{\delta z^L}\frac{\delta C}{\delta a^L}$$

$$\frac{\delta C}{\delta b^L} = \frac{1}{n}\sum_{k=0}^{n-1}\frac{\delta C_k}{\delta b^L}$$

¿Qué sucede cuando vamos más allá de la capa de salida y la capa oculta anterior? La regla de la cadena se aplica una vez más, y la derivada cambia teniendo en cuenta sus parciales. Por ejemplo, la derivada a continuación tiene en cuenta los parciales de la función de costo con respecto a un número de activación de entrada:

$$\frac{\delta C}{\delta a^{L-1}} = \frac{\delta z^L}{\delta a^{L-1}}\frac{\delta a^L}{\delta z^L}\frac{\delta C}{\delta a^L}$$

$$\frac{\delta C}{\delta a^{L-1}} = w^L\sigma'(z^L)2(a^L - y)$$

Calculando cada derivada de cada peso y sesgo, se puede encontrar el vector gradiente. Aunque uno podría intentar calcular el gradiente de una red neuronal a mano, el vector suele estar en dimensiones complejas incomprensibles para nosotros. Por lo tanto, con ayuda computacional, nuestra red neuronal puede realizar cálculos tan intrincados y repetirlos cientos, si no miles de veces hasta alcanzar el mínimo.

$$\nabla C = \begin{bmatrix} \frac{\delta C}{\delta w_1} \\ \frac{\delta C}{\delta b_1} \\ \vdots \\ \frac{\delta C}{\delta w_L} \\ \frac{\delta C}{\delta b_L} \end{bmatrix}$$

8.24 Descenso de Gradiente

Para una función $f(x) = f(x_1, x_2, \ldots, x_d)$, y un vector unitario $u = (u_1, u_2, \ldots, u_d)$, entonces la derivada direccional está definida como:

$$r_u f(x) = \lim_{h\to 0}\frac{f(x+hu) - f(x)}{h}.$$

Estamos interesados en funciones f que son diferenciables; esto implica que $\nabla f(x)$ está bien definido para todos los x y u.

Sea $(e_1, e_2, \ldots, e_d \in R^d$ un conjunto específico de vectores unitarios de manera que $e_i = (0, 0, \ldots, 0, 1, 0, \ldots, 0)$, donde para e_i, el e_i está en la i-ésima coordenada.

Entonces, definimos:

$$\nabla f(x) = \nabla e_i f(x) = \frac{d}{dx_i} f(x).$$

Es la derivada en la i-ésima coordenada, tratando todas las demás coordenadas como constantes. Ahora podemos, para una función diferenciable f, definir el gradiente de f como:

$$\nabla f = \frac{df}{dx_1}\mathbf{e}_1 + \frac{df}{dx_2}\mathbf{e}_2 + \ldots + \frac{df}{dx_d}\mathbf{e}_d = \begin{pmatrix} \frac{df}{dx_1} \\ \frac{df}{dx_2} \\ \vdots \\ \frac{df}{dx_d} \end{pmatrix}.$$

Nótese que ∇f es una función de R^d a R^d, que podemos evaluar en cualquier punto $x \in R^d$.

El "learning rate" es un hiperparámetro fundamental en el entrenamiento de modelos de aprendizaje automático, incluyendo redes neuronales. Esta tasa determina la magnitud de los ajustes realizados a los pesos de la red en cada paso durante el proceso de optimización.

Cuando un modelo se entrena, se utiliza un algoritmo de optimización (por ejemplo, el descenso de gradiente) para ajustar los pesos de la red con el fin de minimizar la función de pérdida. El learning rate controla cuánto se ajustan estos pesos en cada iteración del algoritmo de optimización.

Una tasa de aprendizaje baja puede resultar en convergencia más lenta del modelo, pero puede ayudar a evitar oscilaciones o divergencia en la optimización. Por otro lado, una tasa de aprendizaje alta puede acelerar la convergencia, pero también puede resultar en oscilaciones alrededor del mínimo global o incluso en divergencia.

Seleccionar una tasa de aprendizaje apropiada es crucial para el éxito del entrenamiento del modelo. A menudo, se realiza mediante ajustes empíricos y técnicas de búsqueda, como la validación cruzada. Además, es común utilizar técnicas de ajuste dinámico del learning rate, como la reducción de la tasa de aprendizaje a medida que avanza el entrenamiento, para obtener un equilibrio entre la convergencia rápida y la estabilidad del modelo.

8.25 Tipos de Gradiente Descendente

Los optimizadores son algoritmos utilizados en el entrenamiento de modelos de aprendizaje automático para minimizar una función de pérdida y mejorar el rendimiento

del modelo.

1. **Descenso de gradiente estocástico (SGD)**:
   - Es el optimizador más básico y ampliamente utilizado.
   - Actualiza los pesos de la red en función del gradiente de la función de pérdida calculado sobre un único ejemplo de entrenamiento en cada paso.
   - Es eficiente computacionalmente y fácil de implementar.
   - Puede ser inestable debido a la alta variabilidad en las actualizaciones de los pesos.
2. **Descenso de gradiente con momento (Momentum)**:
   - Introduce un término de momento para suavizar las actualizaciones de los pesos.
   - En cada paso, el término de momento considera la dirección y la magnitud de las actualizaciones anteriores y ajusta la dirección de la actualización de los pesos en consecuencia.
   - Ayuda a acelerar la convergencia y a superar los mínimos locales poco profundos.
3. **Adagrad**:
   - Adapta la tasa de aprendizaje para cada parámetro de la red en función del historial de gradientes.
   - Los parámetros que tienen gradientes más grandes tienen una tasa de aprendizaje reducida, y viceversa.
   - Es útil para problemas en los que los parámetros tienen magnitudes de gradientes muy diferentes.
4. **RMSprop**:
   - Similar a Adagrad, pero utiliza una media móvil exponencial de los cuadrados de los gradientes en lugar de acumularlos.
   - Ayuda a mitigar el problema de que la tasa de aprendizaje se vuelva demasiado pequeña en Adagrad.
   - Adecuado para problemas no estacionarios donde la magnitud de los gradientes puede variar con el tiempo.
5. **Adam (Adaptive Moment Estimation)**:

- Combina los conceptos de momentum y RMSprop.
- Mantiene un promedio móvil exponencial tanto de los gradientes pasados como de los cuadrados de los gradientes pasados.
- Es eficaz en una amplia gama de problemas y es uno de los optimizadores más populares debido a su rendimiento generalmente sólido.

8.26 Regularización

La regularización es un conjunto de técnicas utilizadas en el entrenamiento de modelos de aprendizaje automático para reducir el sobreajuste (overfitting) y mejorar la capacidad de generalización del modelo.

8.26.1 Early Stopping

El early stopping es una técnica utilizada en el entrenamiento para evitar el sobreajuste (overfitting) y mejorar la generalización del modelo. La idea básica detrás del early stopping es detener el proceso de entrenamiento del modelo cuando el rendimiento del mismo en un conjunto de validación comienza a empeorar, es decir, cuando la función de pérdida en el conjunto de validación comienza a aumentar.

El proceso de entrenamiento de un modelo de aprendizaje automático implica iterar sobre los datos de entrenamiento durante varias épocas y ajustar los pesos del modelo para minimizar la función de pérdida en el conjunto de entrenamiento. Sin embargo, si se permite que el proceso de entrenamiento continúe demasiado tiempo, el modelo puede comenzar a sobreajustarse a los datos de entrenamiento, lo que significa que se ajusta demasiado a los detalles específicos de los datos de entrenamiento y no generaliza bien a nuevos datos.

Para implementar el early stopping, se divide el conjunto de datos en conjuntos de entrenamiento y validación. Durante el entrenamiento, se monitoriza el rendimiento del modelo en el conjunto de validación después de cada época. Si el rendimiento del modelo en el conjunto de validación no mejora durante un cierto número de épocas consecutivas (conocido como "patience"), se detiene el entrenamiento y se elige el modelo con el mejor rendimiento en el conjunto de validación como el modelo final.

El early stopping es una técnica efectiva para evitar el sobreajuste y mejorar la capacidad de generalización del modelo. Sin embargo, es importante ajustar correctamente el parámetro de "patience" para evitar detener el entrenamiento prematuramente o permitir que continúe demasiado tiempo. Además, es funda-

mental dividir correctamente los datos en conjuntos de entrenamiento, validación y prueba para garantizar una evaluación justa del rendimiento del modelo.

8.26.2 Dropout

El dropout es una técnica de regularización utilizada en el entrenamiento de redes neuronales para reducir el sobreajuste y mejorar la generalización del modelo. Fue propuesto por primera vez por Geoffrey Hinton y sus colegas en 2012.

La idea principal detrás del dropout es desactivar aleatoriamente un cierto porcentaje de neuronas durante el entrenamiento de cada paso. Esto significa que durante el paso de entrenamiento, las conexiones entre las neuronas se aleatorizan, lo que hace que la red neuronal sea más robusta y menos propensa al sobreajuste.

El dropout se implementa aplicando una máscara binaria a las salidas de las neuronas durante el entrenamiento. Esta máscara se elige aleatoriamente en cada paso de entrenamiento, donde cada elemento de la máscara tiene una probabilidad p de ser 1 (manteniendo la neurona activa) y una probabilidad de $1 - p$ de ser 0 (desactivando la neurona).

Durante la inferencia o evaluación del modelo, todas las neuronas se mantienen activas, pero las salidas se escalan por un factor p para tener en cuenta el efecto del dropout durante el entrenamiento.

El dropout tiene varios beneficios:

- Ayuda a prevenir el sobreajuste al introducir ruido en el proceso de entrenamiento, lo que hace que la red sea más robusta y generalizable.
- Actúa como una forma de promedio ensembles, ya que cada neurona se entrena de manera independiente y se considera como parte de un conjunto diferente de redes neuronales durante cada época de entrenamiento.
- A menudo reduce la necesidad de ajustar otros hiperparámetros, como la tasa de aprendizaje o el tamaño del conjunto de datos de entrenamiento.

Por lo que es una técnica efectiva de regularización que se utiliza comúnmente en el entrenamiento de redes neuronales para mejorar la generalización del modelo y prevenir el sobreajuste.

8.27 Aplicación

Para comparar el rendimiento del modelo de red neuronal use dos modelos base un random forest y una regresión logística con penalización $L1$ dado que:

Random Forest:

- Buen rendimiento en conjuntos de datos grandes con muchas características.
- No requiere normalización de características y maneja bien datos faltantes.
- Tiende a manejar bien tanto datos numéricos como categóricos.
- Menos propenso al sobreajuste que los modelos más complejos como las redes neuronales.
- Proporciona una medida de la importancia de las características.

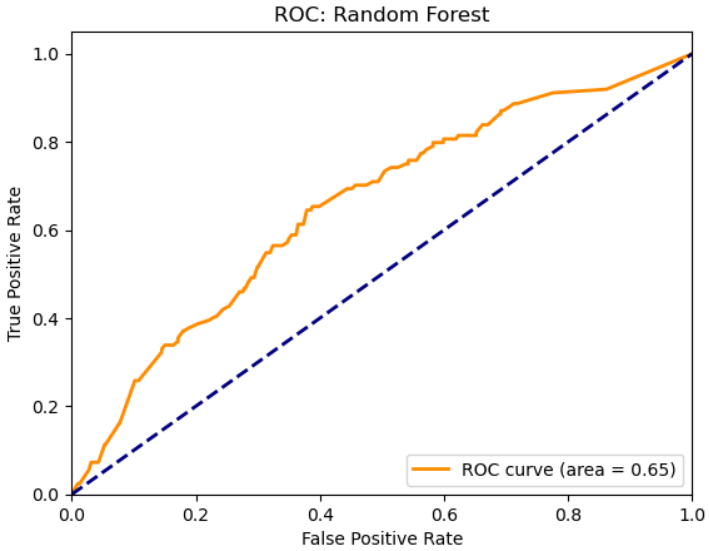

Figure 8.26:

Regresión Logística con Penalización L1:

- Simple y rápido de entrenar y predecir, especialmente en conjuntos de datos grandes.
- Proporciona coeficientes de características directamente interpretables.
- Buen rendimiento en problemas de clasificación binaria linealmente separables.

- Útil para la selección de características, ya que tiende a "eliminar" características irrelevantes al establecer los coeficientes correspondientes a cero.

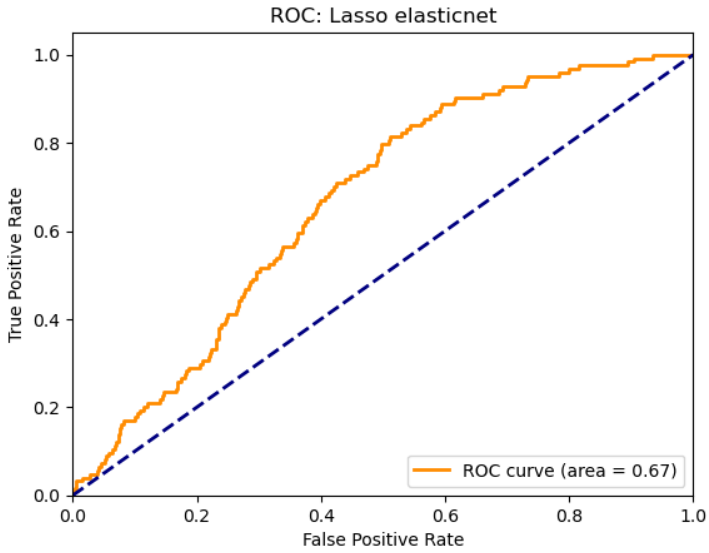

Figure 8.27:

Red:

- Capacidad para aprender características complejas: Las redes neuronales pueden aprender representaciones complejas de los datos gracias a su capacidad para modelar relaciones no lineales entre las características de entrada y la salida. Esto las hace ideales para problemas en los que las relaciones son intrincadas o difíciles de expresar con modelos lineales.
- Aprendizaje de representaciones jerárquicas: Las redes neuronales son capaces de aprender representaciones jerárquicas de los datos, lo que significa que pueden extraer características de bajo nivel y combinarlas para formar características de nivel superior.
- Capacidad para aprender representaciones útiles de los datos: Las redes neuronales son capaces de aprender representaciones útiles de los datos, lo que puede resultar en modelos más eficaces y generalizables. Esto es especialmente útil en problemas donde las características de entrada son difíciles de interpretar o codificar manualmente.

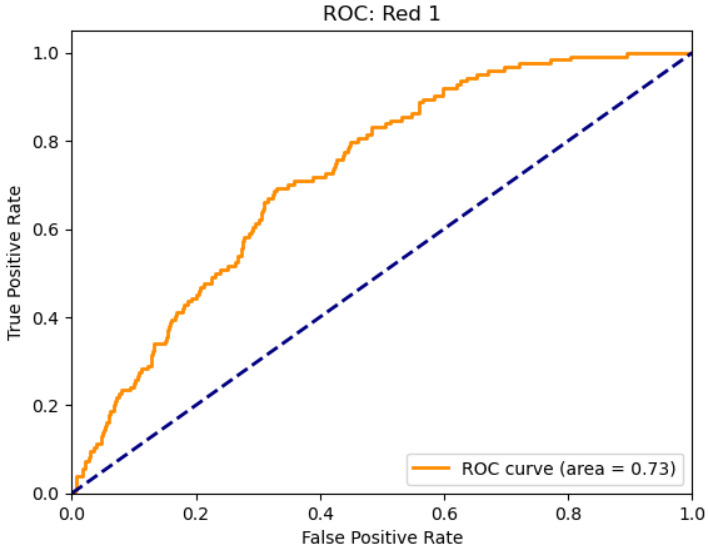
ROC: Red 1
True Positive Rate
False Positive Rate
ROC curve (area = 0.73)
0.0
0.2
0.4
0.6
0.8
1.0

Figure 8.28: